

Тезаурус анализ данных

Табличные данные

└─ pandas

└─ Series / DataFrame

└─ знакомство: `.head()`, `.info()`, `.describe()`, `.shape`, `.columns`

└─ работа с пропусками: `.isna()`, `.fillna()`, `.dropna()`, групповое

заполнение

└─ дубликаты: `.duplicated()`, `.drop_duplicates()`

└─ анализ категориальных данных: `.unique()`, `.value_counts()`

└─ фильтрация: логическая индексация, `.loc[]`, фильтрация по bounding

box

└─ создание признаков: присваивание, `np.where`, `pd.cut`, `lambda`,

one-hot encoding токенов

└─ текстовая очистка: `.str.lower()`, `.str.strip()`, `.str.contains()`, `.str.split()`, `.explode()`

└─ токенизация: `WordPunctTokenizer`, BPE

└─ агрегация: `.groupby()`, `.agg()`

└─ обработка аномалий: IQR, Z-score, `.quantile()`, `.clip()`

└─ меры разброса и формы: `.var()`, `.std()`, `.skew()`, `.kurtosis()`

└─ корреляция: `.corr()`, Pearson, Spearman, Kendall

└─ работа с временными рядами: `rolling`, `pct_change`,

seasonal_decompose

└─ работа с геоданными: координаты (широта, долгота), вычисление геодезического расстояния (`geopy.distance.geodesic`)

└─ визуализация (`matplotlib` + `seaborn` + `plotly`):

└─ гистограмма (`.hist()`)

└─ ящик с усами (`.boxplot()`)

└─ KDE-график (`sns.kdeplot`)

└─ скрипичный график (`sns.violinplot`)

└─ тепловая карта (`sns.heatmap`, `go.Heatmap`)

└─ точечная диаграмма (`sns.scatterplot`) – основа для визуализации

проекций

└─ регрессионный график (`sns.regplot`)

└─ матрица точечных диаграмм (`sns.pairplot`)

└─ `plotly` (интерактивная визуализация):

└─ `Scattermap` (карта-рассеяние)

└─ `subplots` (сетка связанных графиков)

└─ `customdata` + `hovertemplate` (настраиваемые всплывающие окна)

└─ `updatemenus/buttons` (фильтрация через виджеты)

└─ `cross-filtering` (связанные графики)

- |
 - └─ write_html (экспорт в HTML)
- └─ геоданные (geopandas):
 - └─ GeoDataFrame, geometry (точки, полигоны)
 - └─ CRS (EPSG:4326, to_crs)
 - └─ пространственное соединение (gpd.sjoin, predicate='within')
 - └─ загрузка полигонов из GeoJSON

Предобработка

- └─ кодирование категорий: OneHotEncoder, OrdinalEncoder
- └─ масштабирование: StandardScaler
- └─ пайплайны: Pipeline, ColumnTransformer
- └─ Подготовка данных
 - |
 - └─ Разделение на train/valid/test (stratify, KFold)
 - └─ Обнаружение дрейфа (PSI, CSI, KS-тест, t-тест)
 - |
 - └─ Feature Engineering
 - └─ доменные признаки
 - └─ математические признаки (log, exp, квадраты, произведения)
 - └─ пороговые / категориальные преобразования
 - └─ гео-признаки: геодезическое расстояние, час события, стоимость на единицу расстояния

- └─ Оценка важности признаков
 - |
 - └─ статистическая (корреляции, ANOVA, t-test)
 - └─ модельная (коэффициенты, feature_importances_)
 - └─ Векторное представление текста (эмбединги)
 - └─ обучение эмбедингов: Word2Vec (CBOW, Skip-gram), GloVe, FastText (n-граммы)
 - └─ предобученные модели: загрузка через gensim.downloader (glove-twitter-100, fasttext-wiki-news-subwords-300)
 - └─ получение векторов токенов: model.get_vector(word)
 - └─ поиск похожих слов: model.most_similar()
 - └─ вектор предложения: сумма (sum pooling) или среднее (mean pooling)

векторов токенов

- └─ классические текстовые признаки
 - |
 - └─ Bag of Words (BoW): словарь частот, вектор счётчиков
 - └─ TF-IDF: взвешивание по редкости слова в корпусе
 - └─ поиск похожих предложений: косинусное сходство между векторами предложений

Понижение размерности (dimensionality reduction)

- └─ Линейные методы
 - |
 - └─ PCA (максимизация дисперсии, explained_variance_ratio_, components_)
- └─ Нелинейные методы
 - |
 - └─ t-SNE (сохранение локальной структуры, перплексия, KL-дивергенция)

- | | | — openTSNE (ускоренная реализация с многопоточностью)
- | | — UMAP (быстрее, лучше сохраняет глобальную структуру, n_neighbors, min_dist)
- | — Применение
 - | — предварительное сжатие PCA → затем t-SNE/UMAP
 - | — визуализация многомерных данных (scatterplot, цветовая кодировка по классам)

Машинное обучение

- | — Регрессия
 - | — модели: SGDRegressor, RandomForestRegressor
 - | — метрики: MAE, RMSE, R2
- | — Классификация
 - | — модели: LogisticRegression, RandomForestClassifier, CatBoostClassifier
 - | — проблема: дисбаланс классов
 - | — метрики: accuracy, precision, recall, F1, ROC-AUC
- | — Кластеризация
 - | — модель: KMeans
 - | — визуализация кластеров с помощью t-SNE/UMAP
 - | — метрики: инерция, silhouette score

Оценка качества

- | — accuracy (многоклассовая), precision, recall, F1, ROC-AUC

1. Базовые понятия анализа данных

Термин	Определение	Связи
Табличные данные	Данные, организованные в виде строк (наблюдения) и столбцов (признаки).	↔ pandas – основной инструмент работы.
Признак (feature)	Отдельный столбец таблицы, описывающий одно свойство объекта.	Часть DataFrame , может быть числовым или категориальным.
Наблюдение (sample)	Одна строка таблицы – набор значений признаков одного объекта.	Элемент DataFrame .

2. Библиотека pandas

Термин	Определение	Связи
pandas	Библиотека Python для работы с табличными данными.	Используется вместе с numpy , seaborn .
<u>pd.Series</u>	Одномерный массив с именованными индексами.	Состоит из values и index .
<u>pd.DataFrame</u>	Двумерная таблица из нескольких Series с общим индексом.	Основной объект pandas.
<u>Индекс (index)</u>	Метки строк в Series или DataFrame .	Позволяет обращаться к строкам по имени.
Метод <code>.head(n)</code>	Возвращает первые n строк DataFrame.	Для первичного ознакомления.
Метод <code>.info()</code>	Выводит типы данных и количество непустых значений.	Помогает найти пропуски.
Метод <code>.describe()</code>	Возвращает статистику по числовым столбцам.	Даёт представление о распределении.
Атрибут <code>.shape</code>	Кортеж (число строк, число столбцов).	Быстрая оценка объёма данных.
Атрибут <code>.columns</code>	Список названий столбцов.	Используется для доступа по именам.

3. Типы данных и пропуски

Термин	Определение	Связи
Тип <code>category</code>	Оптимизированный тип для категориальных данных с фиксированным набором значений.	Экономит память.
Метод <code>.isna()</code> / <code>.isnull()</code>	Возвращает булеву маску, где <code>True</code> — пропуск.	Используется для подсчёта пропусков: <code>df.isna().sum()</code> .
Метод <code>.fillna(value)</code>	Заменяет пропуски указанным значением (константой, строкой, результатом вычислений).	Можно заполнять медианой, модой, средним или значением из другого столбца.
<u>Заполнение медианой</u>	Стратегия заполнения пропусков медианным значением по группе (например, по стране).	Устойчиво к выбросам, используется для цен.

Термин	Определение	Связи
Заполнение модой	Заполнение наиболее частым значением в столбце (или по группе).	Для категориальных признаков.
Метод <code>.dropna()</code>	Удаляет строки (или столбцы), содержащие пропуски.	Применяется, когда пропусков мало или они не критичны.

4. Распределение значений

Термин	Определение	Связи
Уникальные значения (unique)	Все различные значения в столбце.	<code>.unique()</code> , <code>.nunique()</code> .
Частотное распределение (value_counts)	Таблица, показывающая, как часто встречается каждое значение.	<code>.value_counts(normalize=True)</code> для долей.

5. Предобработка данных

5.1. Дубликаты

Термин	Определение	Связи
Дубликаты строк	Полностью совпадающие строки (по всем столбцам).	Искажают статистику, завышают частоты.
Метод <code>.duplicated()</code>	Возвращает булеву маску, указывающую на повторяющиеся строки (кроме первого вхождения).	<code>df.duplicated().sum()</code> – количество дубликатов.
Метод <code>.drop_duplicates()</code>	Удаляет дубликаты. По умолчанию оставляет первую запись.	Можно настроить параметры <code>keep</code> и <code>subset</code> .

5.2. Аномалии (выбросы)

Термин	Определение	Связи
Аномалия (выброс)	Значение, значительно отклоняющееся от остальных наблюдений.	Может быть ошибкой ввода, редким валидным случаем или систематическим искажением.
Бизнес-логика	Определение границ аномалий на основе экспертных знаний (например, цена не может быть отрицательной).	Наиболее интерпретируемый подход.
IQR (межквартильный размах)	Разность между третьим и первым квартилями: $IQR = Q3 - Q1$.	Используется для выявления выбросов: границы $[Q1 - 1,5 \times IQR, Q3 + 1,5 \times IQR]$.
Z-score (стандартизованная оценка)	$z = (x - \mu) / \sigma$. Значения с $z > 3$ считаются выбросами.	Требуется приблизительно нормального распределения.
Метод <code>.quantile(q)</code>	Возвращает значение q-го квантиля (q от 0 до 1).	Используется для вычисления IQR.
Метод <code>.clip(lower, upper)</code>	Ограничивает значения указанными нижней и верхней границами.	Стратегия обработки выбросов без удаления.
Сегментация	Разделение данных на категории на основе порогов (например, дешёвые / нормальные / дорогие).	Альтернатива удалению выбросов.
Визуализация выбросов	Гистограмма (<code>.hist()</code>) и ящик с усами (<code>.boxplot()</code>) помогают обнаружить аномалии.	Быстрый способ увидеть хвосты распределения.

5.3. Очистка текстовых данных

Термин	Определение	Связи
Несогласованный текст	Проблемы: разные регистры, лишние пробелы, опечатки, разные форматы одной сущности.	Мешает группировке и анализу.
Метод <code>.str.lower()</code> / <code>.str.upper()</code>	Приводит строки к нижнему/верхнему	Унификация регистра.

Термин	Определение	Связи
	регистру.	
Метод <code>.str.strip()</code>	Удаляет пробелы в начале и конце строки.	Устраняет лишние пробелы.
Метод <code>.str.translate()</code>	Удаляет или заменяет символы по таблице перевода.	Используется с <code>str.maketrans('', '', punctuation)</code> для удаления знаков препинания.
Метод <code>.str.replace(pattern, repl)</code>	Заменяет подстроки по шаблону (можно словарём).	Для исправления опечаток и синонимов.
Метод <code>.str.contains(pattern)</code>	Проверяет, содержит ли строка заданную подстроку (регулярное выражение).	Полезна для анализа текстовых описаний (например, поиск слов «fruit»).

5.4. Работа со списками в ячейках

Термин	Определение	Связи
Метод <code>.str.split(delimiter)</code>	Разделяет строку на части по разделителю, возвращает <code>Series</code> списков.	Полезен, когда в одной ячейке перечислено несколько значений (например, жанры, страны).
Метод <code>.explode()</code>	Преобразует каждый элемент списка в отдельную строку, дублируя остальные столбцы.	Позволяет провести анализ частот по каждому элементу списка.

5.5. Токенизация текста

Термин	Определение	Связи
<u>Токенизация текста (tokenization)</u>	Процесс разбиения текста на меньшие единицы (токены): слова, символы или субслова.	Используется для построения признаков из текста.
<u>Word-level токенизация</u>	Разбиение текста на слова и знаки пунктуации (например, с помощью <code>WordPunctTokenizer</code> из NLTK).	Удобна для интерпретации, но приводит к большому размеру словаря.
<u>Char-level токенизация</u>	Разбиение текста на отдельные символы (включая пробелы и знаки).	Маленький словарь, но очень длинные последовательности.

Термин	Определение	Связи
Byte-Pair Encoding (BPE)	Алгоритм субсловной токенизации: начинается с символов, итеративно объединяет самые частые пары токенов до достижения нужного размера словаря.	Компромисс между word и char-токенизацией; эффективно работает с редкими словами.
WordPunctTokenizer	Токенизатор из библиотеки NLTK, разделяющий строку на слова и пунктуацию.	Прост в использовании, подходит для английских текстов.

5.6. Векторное представление текста (эмбединги)

Термин	Определение	Связи
Эмбединг (embedding)	Векторное представление токена (слова, субслова) в непрерывном пространстве, обученное так, чтобы семантически близкие слова имели близкие векторы.	Основа для Word2Vec , GloVe, FastText .
Word2Vec	Алгоритм обучения эмбедингов слов с помощью нейронной сети. Две архитектуры: CBOW (предсказание слова по контексту) и Skip-gram (предсказание контекста по слову).	Реализован в <code>gensim.models.Word2Vec</code> .
GloVe (Global Vectors)	Метод получения эмбедингов на основе факторизации матрицы встречаемости слов (co-occurrence matrix) в корпусе.	Модель <code>glove-twitter-100</code> в <code>gensim.downloader</code> .
FastText	Расширение Word2Vec, учитывающее n-граммы символов. Позволяет получать эмбединги для редких слов и слов, отсутствовавших в обучающем корпусе (out-of-vocabulary).	Модель <code>fasttext-wiki-news-subwords-300</code> в <code>gensim.downloader</code> .
Предобученная модель эмбедингов	Готовая модель, обученная на большом корпусе (Wikipedia, Twitter, новости). Загружается через <code>gensim.downloader.api.load()</code> .	Используется без дополнительного обучения на собственном корпусе.
Векторизация текста через суммирование (sum pooling)	Получение вектора текста как суммы векторов всех входящих в него токенов (с использованием предобученных эмбедингов).	Применяется для классификации текстов и поиска похожих предложений.

Термин	Определение	Связи
Векторизация текста через среднее (mean pooling)	Вектор текста = среднее арифметическое векторов всех токенов.	Альтернатива суммированию; меньше зависит от длины текста.

5.7. Bag of Words и TF-IDF

Термин	Определение	Связи
Bag of Words (BoW)	Представление текста в виде вектора, где каждый элемент соответствует частоте (количеству вхождений) определённого слова из предварительно построенного словаря.	Не учитывает порядок слов, прост в реализации.
TF-IDF (Term Frequency – Inverse Document Frequency)	Метод взвешивания слов, учитывающий частоту слова в документе (TF) и редкость слова в корпусе (IDF). Формула: $tfidf(t,d) = tf(t,d) \cdot \log(N / df(t) + 1)$	Улучшает BoW, подавляя частые, но малоинформативные слова.

6. Фильтрация данных

Термин	Определение	Связи
Логическая индексация	Выбор строк по условию (булевой маске).	<code>df[условие]</code> .
Метод <code>.loc[]</code>	Доступ по меткам или булевым условиям.	<code>df.loc[условие, столбцы]</code> .
Комбинация условий	Использование <code>&</code> (И) и <code>`</code>	<code>`</code> (ИЛИ) с обязательными скобками.

7. Создание новых признаков

Термин	Определение	Связи
Прямое присваивание	<code>df['новый'] = значения .</code>	Изменяет исходный DataFrame.
Функция <code>np.where()</code>	Условное создание значений: <code>np.where(условие, true_val, false_val) .</code>	Бинарная или вложенная классификация.
Функция <code>pd.cut()</code>	Разбивает непрерывную переменную на интервалы (корзины).	<code>pd.cut(x, bins, labels) .</code>
<u>Лямбда-функции (lambda)</u>	Безымянная функция для простых преобразований.	Используется с <code>.apply()</code> или в качестве аргумента в других методах.
<u>Производный признак</u>	Новый столбец, полученный из существующих (например, сумма, разность, категория на основе квантилей).	Улучшает качество анализа.
One-hot encoding на основе токенов	Для отобранных токенов создаётся бинарный признак: 1 – токен присутствует в тексте, 0 – отсутствует.	Применяется после токенизации; результат – таблица признаков для классификации.
<u>Разница частот токенов между классами</u>	Абсолютная разность долей встречаемости токена в позитивных и негативных текстах.	Позволяет выбрать наиболее информативные токены для one-hot encoding.

8. Агрегация и группировка

Термин	Определение
<u>Группировка (groupby)</u>	Разбиение данных на группы по значениям одного или нескольких столбцов.
<u>Агрегирующая функция</u>	Функция, вычисляющая сводную статистику по каждой группе (среднее, сумма, медиана и т.д.).
Метод <code>.agg()</code>	Применение нескольких агрегирующих функций одновременно.

9. Корреляционный анализ

Термин	Определение	Связи
Корреляция	Статистическая мера связи между двумя числовыми признаками.	Значение от -1 до 1.
Кoeffициент корреляции Пирсона (Pearson)	Мера линейной зависимости. Чувствителен к выбросам.	Требует приблизительно нормального распределения.
Кoeffициент ранговой корреляции Спирмена (Spearman)	Мера монотонной (необязательно линейной) зависимости. Основан на рангах.	Более устойчив к выбросам.
Метод <code>.corr(method=...)</code>	Вычисляет корреляционную матрицу для числовых столбцов DataFrame.	<code>method = 'pearson'</code> (по умолчанию) или <code>'spearman'</code> .
Косинусное сходство (cosine similarity)	Мера схожести двух векторов, определяемая как косинус угла между ними. Формула: $\cos(A \angle B)$	Используется для поиска ближайших векторов, в том числе для поиска похожих предложений (<code>sklearn.metrics.pairwise.cosine_similarity</code>).

10. Визуализация (дополнение)

Термин	Определение	Связи
Гистограмма	График распределения частот числового признака.	<code>.plot.hist()</code> , <code>.hist()</code> .
Ящик с усами (boxplot)	График, показывающий медиану, квартили и	<code>.plot.box()</code> . Используется для обнаружения аномалий.

Термин	Определение	Связи
	возможные выбросы.	
Count plot (столбчатая диаграмма частот)	График, показывающий количество (или долю) наблюдений для каждой категории.	<code>sns.countplot()</code> или <code>df['column'].value_counts().plot(kind='bar')</code> .
Тепловая карта корреляций	Визуализация корреляционной матрицы с помощью цветовой шкалы.	<code>sns.heatmap(df.corr(), annot=True, cmap='coolwarm')</code> .

11. Источники данных

Формат	Метод загрузки
CSV	<code>pd.read_csv()</code>
Excel	<code>pd.read_excel()</code>
JSON	<code>pd.read_json()</code>
Встроенные датасеты	<code>seaborn.load_dataset()</code>

12. Распределения вероятностей в анализе данных (расширение)

Термин	Определение	Связи
Геометрическое распределение Geom(p)	Распределение числа испытаний Бернулли до первого успеха (включительно).	<code>scipy.stats.geom</code> . Используется в BTYD для моделирования числа покупок до «смерти» пользователя.
Экспоненциальное распределение Exp(λ)	Распределение времени между независимыми событиями в пуассоновском потоке.	<code>scipy.stats.expon(scale=1/λ)</code> . В BTYD — время до следующей покупки.

Термин	Определение	Связи
Бета-распределение Beta(α, β)	Распределение вероятности на отрезке $[0, 1]$; гибко моделирует гетерогенность параметра p .	<code>scipy.stats.beta</code> . Используется в BG/NBD для вариабельности вероятности «смерти».
Гамма-распределение Gamma(α, β)	Распределение положительной случайной величины; моделирует гетерогенность интенсивности покупок λ .	<code>scipy.stats.gamma(a=α, scale=1/β)</code> .
Смесь распределений (mixture distribution)	Линейная комбинация нескольких распределений с весами (вероятностями смеси).	Пример: загрязнённое нормальное распределение: $(1 - \epsilon) \cdot N(\mu, \sigma^2) + \epsilon \cdot N(\mu, \alpha\sigma^2)$.

13. Генерация случайных величин и работа с распределениями

Термин	Определение	Связи
numpy.random	Модуль для генерации псевдослучайных чисел из различных распределений.	<code>np.random.geometric(p, size)</code> , <code>np.random.exponential(scale, size)</code> .
scipy.stats	Модуль, предоставляющий объекты распределений с методами <code>.rvs()</code> , <code>.pdf()</code> , <code>.cdf()</code> , <code>.ppf()</code> , <code>.pmf()</code> .	Более медленный, но удобный для теоретических расчётов.
Фиксация seed	<code>np.random.seed(42)</code> — обеспечивает воспроизводимость результатов, часто фиксирует весь рандом, включая другие библиотеки.	Обязательно при моделировании.

14. Ядерное сглаживание (Kernel Density Estimation)

Термин	Определение	Связи
gaussian_kde	Класс в <code>scipy.stats</code> для построения сглаженной оценки плотности по выборке.	<code>kde = gaussian_kde(data, bw_method='scott')</code> .
Параметр bw_method (bandwidth)	Регулирует «гладкость» оценки: малые значения → высокая детализация (шум), большие → излишнее сглаживание.	<code>bw_method='scott'</code> (оптимально по умолчанию), <code>bw_method=0.5</code> (для малых выборок).

15. Продвинутая визуализация (matplotlib / seaborn)

Термин	Определение	Пример использования
Аннотация со стрелкой	<code>ax.annotate(text, xy, xytext, arrowprops)</code> — выделение точек с визуальной связью.	Указание на «тяжёлые хвосты» или бимодальность.
Текстовый блок с фоном	<code>ax.text(x, y, text, bbox={'facecolor':'yellow', 'alpha':0.5, 'pad':5})</code> .	Пояснение параметров смеси, интерпретация графиков.
Вертикальные / горизонтальные линии	<code>ax.axvline(x, color, linestyle)</code> , <code>ax.axhline(y)</code> .	Отметка средних значений, медианы, порогов.
Заливка области (fill_between)	<code>ax.fill_between(x, y1, y2, color, alpha)</code> .	Визуализация доверительных интервалов, области между кривыми (например, функция риска).
Заливка интервала (axvspan)	<code>ax.axvspan(xmin, xmax, color, alpha)</code> .	Выделение доверительного интервала прогноза.
Сетка графиков (subplots)	<code>fig, axes = plt.subplots(nrows, ncols, figsize, sharex, sharey)</code> .	Сравнение нескольких распределений или эволюции процесса (например, приближение геометрического распределения к экспоненциальному).
Параметры гистограммы	<code>density=True</code> — нормализация (площадь = 1); <code>bins=range(min, max+1)</code> — для дискретных данных.	Сравнение эмпирической гистограммы с теоретической плотностью.

Термин	Определение	Пример использования
Легенда (legend)	<code>ax.legend()</code> — отображает подписи элементов.	Обязательна при нескольких кривых на одном графике.

16. Работа с датами и временными интервалами

Термин	Определение
Тип <code>datetime</code>	<code>pd.to_datetime()</code> — преобразование строки в дату.
Разница между датами	<code>(date1 - date2).days</code> — число дней между событиями.
Группировка по времени	<code>df.groupby(pd.Grouper(key='date', freq='M'))</code> — агрегация по месяцам.

17. Модель Buy Till You Die (BTYD) / BG/NBD

Термин	Определение
BG/NBD (Beta-Geometric / Negative Binomial Distribution)	Вероятностная модель для прогнозирования количества будущих покупок и вероятности оттока клиентов на основе истории транзакций.
«Смерть» клиента (churn)	Клиент с вероятностью p перестаёт совершать покупки навсегда (геометрическое распределение).
Интенсивность покупок λ	Время до следующей покупки $\sim \text{Exp}(\lambda)$; λ имеет гамма-распределение (гетерогенность).
Параметры модели	α, β — параметры гамма-распределения для λ ; α_p, β_p — параметры бета-распределения для p .
Ресенсу (давность)	Время от первой до последней покупки (в днях).
Frequency (частота повторных покупок)	Количество повторных покупок (<code>total_purchases - 1</code>).
T (возраст клиента)	Время от первой покупки до текущей даты (или конца периода наблюдения).
Функция выживания $S(t)$	Вероятность того, что клиент «жив» (не ушёл) спустя время t после последней покупки.
Функция риска (hazard) $h(t)$	Вероятность «смерти» в момент t при условии, что клиент дожил до t ; $h(t) = 1 - S(t)$ для дискретного времени.

Термин	Определение
Прогноз числа покупок на следующие N дней	Симуляция или аналитическая формула (conditional expectation) на основе оценённых параметров α , β , α_p , β_p , recency, frequency, T.

18. Оценка параметров BG/NBD в Python

Термин	Описание
pymc_marketing.clv.BetaGeoModel	Класс для байесовской оценки параметров BG/NBD.
Подготовка данных	Для каждого клиента: frequency , recency , T .
Метод <code>.fit()</code>	Обучает модель (MCMC или вариационный вывод).
Прогноз	<code>.expected_purchases(future_t)</code> — ожидаемое количество покупок за future_t дней.

19. Основные задачи машинного обучения

Термин	Определение	Связи
Регрессия (regression)	Задача предсказания непрерывной числовой переменной (например, цены алмаза).	Используются модели: SGDRegressor , RandomForestRegressor .
Классификация (classification)	Задача отнесения объекта к одному из дискретных классов (например, ушёл клиент или остался).	Используются модели: LogisticRegression , RandomForestClassifier , CatBoostClassifier .
Кластеризация (clustering)	Задача обучения без учителя: поиск скрытых групп в данных (например, сегментация покупателей).	Основной алгоритм: KMeans .

20. Модели регрессии

Термин	Определение
<u>SGDRegressor</u>	Линейная регрессия, обучаемая стохастическим градиентным спуском. Чувствительна к масштабу признаков.
<u>RandomForestRegressor</u>	Ансамбль решающих деревьев, не требует нормализации, лучше справляется с нелинейностями.

21. Модели классификации

Термин	Определение
<u>LogisticRegression</u>	Линейный классификатор с сигмоидной функцией активации. Используется для бинарной классификации.
<u>RandomForestClassifier</u>	Ансамбль решающих деревьев для классификации. Устойчив к выбросам и не требует масштабирования.
<u>CatBoostClassifier</u>	Градиентный бустинг на деревьях, эффективно работает с категориальными признаками без предварительного кодирования.

22. Кластеризация

Термин	Определение
<u>KMeans</u>	Алгоритм кластеризации, минимизирующий сумму квадратов расстояний от точек до центров кластеров (инерцию).
<u>Inertia</u>	Сумма квадратов расстояний от каждого наблюдения до центроида его кластера. Убывает с ростом числа кластеров.
<u>Silhouette score</u>	Метрика качества кластеризации, оценивающая, насколько точка похожа на свой кластер по сравнению с соседними. Принимает значения от -1 до 1.

23. Предобработка для моделей

Термин	Определение	Связи
OneHotEncoder	Преобразование категориального признака в набор бинарных столбцов (по одному на каждую категорию). Не создаёт ложного порядка.	Увеличивает размерность, но безопасен для любых моделей.
OrdinalEncoder / LabelEncoder	Замена категорий целыми числами (0, 1, 2...). Вносит искусственный порядок.	Опасен для линейных моделей, но допустим для деревьев.
StandardScaler	Нормализация: вычитает среднее и делит на стандартное отклонение (получает распределение с $\mu=0$, $\sigma=1$).	Обязателен для SGD, полезен для логистической регрессии; не влияет на деревья.
ColumnTransformer	Позволяет применить разные трансформации к разным группам столбцов в одном пайплайне.	Например, числовые масштабировать, категориальные – закодировать.

24. Оценка качества моделей (метрики)

Термин	Определение	Формула / Примечание
MAE (Mean Absolute Error)	Средняя абсолютная ошибка регрессии.	$\frac{1}{n} \sum y_i - \hat{y}_i $
RMSE (Root Mean Squared Error)	Корень из среднего квадрата ошибки; сильнее штрафует за большие отклонения.	$\sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$
R² (коэффициент детерминации)	Доля дисперсии, объяснённая моделью.	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$
Accuracy	Доля правильных ответов в классификации.	$(TP+TN)/(TP+TN+FP+FN)$. Бесполезна при сильном дисбалансе классов.
Precision (точность)	Доля объектов, отнесённых к классу 1, которые действительно являются классом 1.	$TP/(TP+FP)$.
Recall (полнота)	Доля реальных объектов класса 1,	$TP/(TP+FN)$.

Термин	Определение	Формула / Примечание
	правильно предсказанных.	
F1-score	Среднее гармоническое precision и recall.	$2 \cdot (\text{Prec} \cdot \text{Rec}) / (\text{Prec} + \text{Rec})$.
ROC-AUC (Area Under ROC Curve)	Площадь под ROC-кривой (зависимость True Positive Rate от False Positive Rate). Значение 0,5 – случайное угадывание, 1,0 – идеальный классификатор.	<code>sklearn.metrics.roc_auc_score</code> , <code>roc_curve</code> . Широко используется для бинарной классификации, устойчива к дисбалансу классов.
Silhouette score	Оценка качества кластеризации. Высокое значение (близкое к 1) означает хорошо разделённые компактные кластеры.	Для KMeans.
Inertia	Сумма квадратов расстояний до центроидов. Используется для выбора числа кластеров (метод локтя).	

25. Дисбаланс классов

Термин	Определение
Дисбаланс классов	Ситуация, когда один класс (например, «клиент не ушёл») значительно преобладает над другим.
Accuracy парадокс	При дисбалансе accuracy может быть высокой, даже если модель ничего не предсказывает (всегда предсказывает большинство).
Почему важны precision/recall/F1/ROC-AUC	Эти метрики учитывают ошибки по каждому классу и дают объективную оценку в условиях дисбаланса.

26. Пайплайны и трансформеры (sklearn.pipeline)

Термин	Определение
Pipeline	Объект, объединяющий последовательность трансформаций и финальную модель. Упрощает кросс-валидацию и предотвращает утечку данных.
fit / transform / fit_transform	<code>fit</code> – вычисляет параметры (например, среднее и дисперсию на обучающей выборке); <code>transform</code> – применяет преобразование; <code>fit_transform</code> – комбинация.
<u>Утечка данных (data leakage)</u>	Использование информации из тестовой выборки при вычислении статистик (например, масштабирование на всём датасете). Недопустимо. Все преобразования должно быть возможно повторить с совершенно новым датасетом без переобучения модели

27. Работа с порогами классификации

Термин	Определение
<u>Порог классификации (threshold)</u>	Значение, выше которого вероятность относит объект к классу 1 (обычно 0.5).
<u>Влияние порога на метрики</u>	Понижение порога увеличивает recall (находим больше объектов класса 1) за счёт снижения precision (больше ложных срабатываний). Повышение порога – наоборот.

28. Нормализация и стандартизация

Термин	Определение
<u>Нормализация (normalization)</u>	Приведение признаков к единому масштабу.
StandardScaler	Центрирование и масштабирование к единичной дисперсии. Рекомендуется для линейных моделей (SGD, логистическая регрессия).
Зачем нормализация	Градиентный спуск сходится быстрее, коэффициенты становятся сравнимыми, регуляризация работает корректно. Для деревьев нормализация не нужна.

29. Разделение данных на выборки

Термин	Определение	Связи
<u>Train (обучающая выборка)</u>	Часть данных, используемая для подбора весов и коэффициентов модели.	На ней модель «видит» ответы.
<u>Validation (валидационная выборка)</u>	Часть данных, используемая для настройки гиперпараметров и ранней остановки.	Не участвует в обучении, но используется для выбора лучшей конфигурации.
<u>Test (тестовая выборка)</u>	Часть данных, используемая только для финальной оценки качества модели.	Запрещено использовать при настройке модели (во избежание утечки данных).
<u>Стратификация (stratification)</u>	Разбиение, сохраняющее пропорции целевой переменной (например, классов) в каждой выборке.	Параметр <code>stratify</code> в <code>train_test_split</code> .
<u>KFold (k-блочная кросс-валидация)</u>	Метод повторного разбиения данных на k блоков, где каждый блок по очереди становится валидационным.	Полезна для небольших датасетов.

30. Дрейф данных (Data Drift)

Термин	Определение	Связи
<u>Data Drift</u>	Изменение статистических свойств данных между выборками (например, между train и test).	Может привести к ухудшению модели в эксплуатации.
<u>Covariate Drift</u>	Изменение распределения признаков (X) при неизменном законе.	Обнаруживается сравнением <code>X_train</code> и <code>X_test</code> .
<u>Label Drift</u>	Изменение распределения целевой переменной (y).	Характерно для задач с меняющейся частотой классов.
<u>Concept Drift</u>	Изменение связи между признаками и целевой переменной.	Сложнее всего обнаружить, требует мониторинга во времени.

Термин	Определение	Связи
<u>PSI (Population Stability Index)</u>	Метрика изменения распределения числового признака между двумя выборками.	$PSI = \sum (Actual\% - Expected\%) * \ln(Actual\%/Expected\%)$. Значения: <0.1 – стабильно, $0.1-0.2$ – небольшие изменения, ≥ 0.2 – значительный дрейф.
<u>CSI (Characteristic Stability Index)</u>	PSI для категориальных признаков (аналогичная формула по категориям).	Позволяет оценить дрейф категориальных переменных.

31. Статистические тесты для обнаружения дрейфа

Термин	Определение	Применение
<u>KS-тест (Kolmogorov–Smirnov)</u>	Непараметрический тест равенства распределений двух непрерывных выборок.	<code>scipy.stats.ks_2samp()</code> . Н ₀ : распределения одинаковы (дрейфа нет). $p\text{-value} < 0.05$ – дрейф значим.
<u>t-тест Стьюдента</u>	Проверка равенства средних двух выборок (предполагается нормальность или большой объём).	<code>scipy.stats.ttest_ind()</code> . Н ₀ : средние равны.

32. Оценка важности признаков (Feature Importance)

Термин	Определение	Модели
Коэффициенты линейной регрессии	Абсолютные значения весов признаков, показывающие их вклад при условии масштабирования.	<code>LinearRegression</code> , <code>Lasso</code> (L1-регуляризация обнуляет неважные признаки).
<u>Feature Importances (деревья)</u>	Частота использования признака при разбиениях в деревьях; суммарное уменьшение неопределённости.	<code>RandomForestRegressor</code> , <code>RandomForestClassifier</code> .
<u>Feature Importances (CatBoost)</u>	Встроенная оценка важности, основанная на	<code>CatBoostRegressor</code> , <code>CatBoostClassifier</code> .

Термин	Определение	Модели
	среднем улучшении качества при использовании признака.	
Нормализация важности	Приведение значений важности к диапазону [0,1] (делением на максимум) для сравнения между моделями.	<code>importance / max(importance) .</code>

33. Создание новых признаков (Feature Engineering)

Термин	Описание
Доменный признак	Создан на основе бизнес-логики или физического смысла (например, ИМТ, возрастная группа).
Математическое преобразование	Логарифм, экспонента, квадрат, произведение двух признаков для учёта нелинейностей.
<u>Пороговый (бинарный) признак</u>	Метка, достигает ли числовой признак определённого уровня (например, <code>age > 60</code>).
<u>Категоризация непрерывного признака</u>	Преобразование в группы (биннинг) с помощью <code>pd.cut</code> .

34. Оценка значимости признаков (статистическая)

Метод	Описание
Корреляция Пирсона	Линейная связь между числовыми признаками и целевой переменной.
Корреляция Спирмена	Монотонная связь (ранговая) – менее чувствительна к выбросам.
<u>t-тест для бинарного признака</u>	Сравнение средних целевой переменной для двух категорий (например, <code>sex</code>).
<u>ANOVA (F-тест)</u>	Сравнение средних целевой переменной для нескольких категорий (например, <code>region</code>).

35. Пайплайны и трансформации (повторение и уточнение)

Термин	Определение
ColumnTransformer	Применение разных преобразований к разным столбцам (например, масштабирование к числовым, кодирование – к категориальным).
Pipeline	Последовательное применение трансформаций и обучение модели. Упрощает кросс-валидацию и предотвращает утечку данных.

36. Метрики классификации (расширение)

Термин	Определение
Accuracy	Доля правильных ответов. Неинформативна при сильном дисбалансе классов.
Precision/Recall/F1/ROC-AUC	См. разделы 25. Дисбаланс классов – 26. Пайплайны и трансформеры (sklearn.pipeline) .
Multi-class accuracy	Доля правильных ответов в задаче с тремя и более классами.

37. Процесс подбора признаков (Feature Selection)

Шаг	Описание
1. Статистический анализ	Вычисление корреляций, тестов (t-test, ANOVA), отбор признаков с $p\text{-value} < 0.05$.
2. Создание новых признаков	Добавление доменных и математических признаков.
3. Оценка важности через модели	Анализ коэффициентов линейной регрессии, важности деревьев.
4. Итеративное улучшение	Повторное обучение с разными наборами признаков, контроль метрики на валидации.

38. Понижение размерности (Dimensionality Reduction)

Термин	Определение	Связи
Проклятие размерности (curse of dimensionality)	Рост числа признаков приводит к заметному увеличению объёма данных, необходимого для статистически значимых выводов; расстояния между точками теряют различимость.	Проявляется при $D \sim n$ или $D > n$, где D – число признаков, n – число наблюдений.
Линейное понижение размерности	Метод, который проецирует данные на линейное подпространство меньшей размерности.	Пример: PCA.
Нелинейное понижение размерности	Метод, который ищет нелинейный способ понизить размерность с сохранением каких-то характеристик, зачастую расстояния, в каком-то смысле.	Примеры: t-SNE, UMAP.

39. PCA (Principal Component Analysis)

Термин	Определение	Связи
PCA	Линейный метод понижения размерности, находящий ортогональные направления (главные компоненты), вдоль которых дисперсия данных максимальна.	<code>sklearn.decomposition.PCA</code> .
Главная компонента (principal component)	Нормализованный собственный вектор ковариационной матрицы, соответствующий наибольшему собственному значению.	Компоненты упорядочены по убыванию объяснённой дисперсии.
Объяснённая дисперсия (explained variance)	Доля дисперсии исходных данных, сохраняемая при проекции на данную главную компоненту.	Доступна в <code>pca.explained_variance_ratio_</code> .

Термин	Определение	Связи
Суммарная объяснённая дисперсия	Сумма долей дисперсии для первых k компонент. Показывает, сколько информации потеряно при сжатии до k измерений.	Используется для выбора оптимальной размерности (правило локтя).
Правило локтя (elbow rule)	Выбор количества компонент, после которого прирост суммарной объяснённой дисперсии становится незначительным.	Визуализируется графиком <code>explained_variance_ratio_</code> в порядке убывания.
Матрица компонент <code>pca.components_</code>	Матрица размера <code>(n_components, n_features)</code> , строки которой являются главными компонентами (направлениями в исходном пространстве).	Каждая компонента может быть визуализирована как «изображение» (например, для MNIST).
Стандартизация для PCA	Данные должны быть центрированы (вычтено среднее) и масштабированы (приведены к единичной дисперсии).	Влияет на результат, поскольку PCA чувствителен к масштабу признаков.

40. t-SNE (t-distributed Stochastic Neighbor Embedding)

Термин	Определение	Связи
t-SNE	Нелинейный метод понижения размерности, основанный на вероятностном сходстве точек и использующий распределение Стюдента для низкоразмерного отображения.	<code>sklearn.manifold.TSNE</code> (также <code>openTSNE</code> , для ML поддерживает только размерность 2).
Перплексия (perplexity)	Эффективное число ближайших соседей.	Типичные значения: 5–50. Меньшие значения подчёркивают локальную структуру, большие – глобальную.

Термин	Определение	Связи
Скорость обучения (learning rate)	Шаг градиентного спуска при оптимизации расхождения Кульбака–Лейблера.	Типичные значения: 10–1000. При слишком малой – медленная сходимость, при слишком большой – расходимость.
Инициализация (init)	Начальное расположение точек в низкоразмерном пространстве. 'random' – случайное, 'pca' – с помощью PCA (часто даёт лучшие результаты).	Параметр <code>init</code> в TSNE.
Расхождение Кульбака–Лейблера (KL divergence)	Мера различия между распределением вероятностей соседства в исходном и низкоразмерном пространстве. t-SNE минимизирует $KL(P Q)$.	$KL(P Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$
<u>Интерпретация t-SNE</u>	Расстояния между кластерами не имеют количественного смысла, важна только относительная близость точек внутри кластеров.	t-SNE не сохраняет глобальные расстояния и масштабы.

41. UMAP (Uniform Manifold Approximation and Projection)

Термин	Определение	Связи
UMAP	Нелинейный метод понижения размерности, улучшение t-SNE. Быстрее t-SNE и лучше сохраняет глобальную структуру. Зачастую имеет схожие с t-SNE кластеры, из-за тенденции сжимать кластеры, по возможности, стоит использовать вместе с t-SNE.	Библиотека <code>umap-learn</code> .
n_neighbors	Аналог перплексии; размер локального окружения. Меньшие значения фокусируются на локальной структуре, большие – на глобальной.	Параметр <code>n_neighbors</code> в <code>umap.UMAP</code> .
min_dist	Минимальное допустимое расстояние между точками в низкоразмерном пространстве. Меньшие значения приводят к более плотным кластерам.	Параметр <code>min_dist</code> (по умолчанию 0.1).

Термин	Определение	Связи
Метрика (metric)	Функция расстояния, используемая для построения графа соседства. По умолчанию <code>'euclidean'</code> .	Параметр <code>metric</code> .

42. Сравнение методов понижения размерности

Характеристика	PCA	t-SNE	UMAP
Тип	Линейный	Нелинейный	Нелинейный
Сохраняет глобальную структуру	Да (при достаточном числе компонент)	Нет	Частично
Сохраняет локальную структуру	Нет	Да	Да
Скорость работы	Высокая (на больших данных)	Низкая ($O(n^2)$ или $O(n \log n)$ с приближениями)	Высокая (быстрее t-SNE)
Рекомендуемое применение	Сжатие признаков для ML, предобработка перед t-SNE/UMAP	Визуализация, изучение кластеров, сжатие признаков для ML (только с <code>openTSNE</code>)	Визуализация, изучение кластеров (по возможности, применять и t-SNE), сжатие признаков для ML
Чувствительность к параметрам	Низкая	Высокая (perplexity, learning rate)	Средняя (<code>n_neighbors</code> , <code>min_dist</code>)

43. Подготовка данных и визуализация

Термин	Определение	Связи
Предварительное понижение размерности	Применение PCA (например, до 50 компонент) перед t-SNE или UMAP для ускорения работы и шумоподавления.	Используется, когда исходная размерность слишком велика.

Термин	Определение	Связи
Визуализация проекции	Точечная диаграмма (scatter plot) низкоразмерного представления (2D или 3D) с цветовой кодировкой по меткам классов.	<code>plt.scatter(x, y, c=labels, cmap=...)</code> .
Оценка разделимости кластеров	Насколько хорошо кластеры, соответствующие разным меткам, визуально разделяются в проекции.	Не является точной метрикой, но даёт интуитивное представление о структуре данных.

44. Применение понижения размерности в анализе текстов

Термин	Описание
Визуализация one-hot признаков	После создания бинарных признаков на основе токенов (число признаков может быть велико) применяют PCA, t-SNE или UMAP для снижения размерности и визуализации разделимости классов.

45. Метрика ROC-AUC (дополнение к разделу 25)

Термин	Определение	Связи
ROC-кривая (Receiver Operating Characteristic)	График зависимости True Positive Rate (TPR) от False Positive Rate (FPR) при варьировании порога классификации.	<code>sklearn.metrics.roc_curve</code> .
AUC (Area Under Curve)	Площадь под ROC-кривой. Чем ближе к 1, тем лучше модель разделяет классы. Значение 0,5 соответствует случайному угадыванию.	<code>sklearn.metrics.roc_auc_score</code> . Широко используется для бинарной классификации.

46. Частотный анализ токенов

Термин	Определение	Связи
<u>Частота токена (token frequency)</u>	Количество вхождений токена в текстах определённого класса или во всём корпусе.	Вычисляется с помощью <code>collections.Counter</code> .
Разница частот (frequency difference)	Абсолютная разность долей встречаемости токена в двух классах (например, позитивном и негативном).	Позволяет отобрать наиболее дискриминативные токены для построения признаков.

47. Классификация текстов на основе бинарных признаков токенов

Термин	Описание
One-hot кодирование токенов	Для каждого отобранного токена создаётся признак: 1, если токен встретился в тексте, 0 – в противном случае.
Логистическая регрессия на таких признаках	Простая, но часто эффективная модель для бинарной классификации текстов (например, определение тональности).

48. Обучение модели и оценка качества

Термин	Описание
Разделение выборки	Данные делятся на обучающую (train) и тестовую (test) с сохранением пропорции классов (стратификация).
Обучение	Модель (например, <code>LogisticRegression</code>) обучается на train-наборе.
Прогноз	Для test-набора вычисляются вероятности принадлежности к классу 1.
ROC-AUC	Рассчитывается по этим вероятностям; служит основной метрикой качества.

49. Поиск похожих предложений (semantic similarity search)

Термин	Определение	Связи
Поиск похожих предложений	Задача нахождения в корпусе предложений, наиболее близких по смыслу к заданному запросу.	Используется косинусное сходство между векторами предложений (полученными суммированием эмбедингов токенов). Полезна для анализа текстовых данных, рекомендаций, кластеризации.

50. Геоданные и работа с ними

Термин	Определение	Связи
<u>Геоданные (spatial data)</u>	Данные, содержащие информацию о географических координатах (широта, долгота) или геометрических объектах (точки, линии, полигоны).	Используются для картографического анализа, пространственных соединений.
<u>GeoDataFrame (geopandas)</u>	Таблица, расширяющая <code>pd.DataFrame</code> специальным столбцом <code>geometry</code> , содержащим геометрические объекты (точки, полигоны и т.д.).	<code>gpd.GeoDataFrame()</code> . Позволяет выполнять пространственные операции.
<u>CRS (Coordinate Reference System)</u>	Система координат, задающая, как географические координаты (широта, долгота) проецируются на плоскость.	EPSG:4326 – WGS84 (географические координаты, градусы). <code>to_crs()</code> – перепроецирование.
<u>Точечная геометрия (Point geometry)</u>	Объект <code>shapely.geometry.Point</code> , представляющий одну географическую точку (например, место посадки/высадки).	Создаётся через <code>gpd.points_from_xy(x, y, crs=...)</code> .
Полигональная геометрия (Polygon / MultiPolygon)	Объект, задающий границы территориальной единицы (район, округ, страна) в виде многоугольника (или набора многоугольников).	Загружается из GeoJSON-файлов.

Термин	Определение	Связи
Пространственное соединение (spatial join)	Операция, сопоставляющая каждому объекту (точке) атрибуты полигона, в который эта точка попадает (предикат <code>within</code>).	<code>gpd.sjoin(gdf_points, gdf_polygons, how='left', predicate='within')</code> .
Предикат within	Проверяет, содержится ли геометрия левого операнда полностью внутри геометрии правого.	Используется для определения принадлежности точки к полигону.

51. Интерактивная визуализация с Plotly

Термин	Определение	Связи
Plotly Express (<code>px</code>)	Высокоуровневый интерфейс для быстрого создания интерактивных графиков (включая карты).	<code>plotly.express.scatter_map</code> — точечная карта.
Plotly Graph Objects (<code>go</code>)	Низкоуровневый интерфейс для детальной настройки сложных графиков, включая <code>subplots</code> и связанные фильтры.	<code>make_subplots()</code> , <code>go.Scattermap()</code> , <code>go.Scatter()</code> .
Scattermap (карта-рассеяние)	Слой точечных данных, наложенный на карту (обычно OpenStreetMap или стиль Mapbox).	<code>go.Scattermap(lat=..., lon=..., mode='markers', marker=..., text=...)</code> .
Субплоты (<code>subplots</code>)	Группа из нескольких графиков, расположенных в сетке и связанных общими данными/фильтрами.	<code>fig = make_subplots(rows, cols, subplot_titles)</code> , затем <code>fig.add_trace(trace, row, col)</code> .
Настраиваемое всплывающее окно (<code>customdata</code> + <code>hovertemplate</code>)	Механизм передачи дополнительных данных для отображения при наведении курсора на точку.	<code>customdata</code> — массив данных; <code>hovertemplate</code> — строка с плейсхолдерами <code>% {customdata[...]}</code> .

Термин	Определение	Связи
Фильтрация через виджеты (updatemenus / buttons)	Элементы управления, позволяющие динамически показывать/скрывать слои на графике.	<code>updatemenus c buttons ; visible</code> массива трасс управляется через <code>args</code> .
Связанные графики (cross-filtering)	Выбор категории в одном графике автоматически отображает соответствующие подмножества точек на других графиках.	Реализуется через <code>updatemenus</code> и изменение <code>visible</code> всех трасс.
Экспорт в HTML	Сохранение интерактивного графика в отдельный HTML-файл для просмотра в браузере.	<code>fig.write_html('filename.html')</code> .

52. Преобразования данных для геоаналитики

Термин	Определение	Связи
<u>Геодезическое расстояние (geodesic distance)</u>	Расстояние между двумя точками на поверхности земного эллипсоида (в отличие от евклидова).	<code>geopy.distance.geodesic(pointA, pointB, ellipsoid='GRS-80').miles</code> (или километры).
Вычисление <code>distance_between_points</code>	Новый признак – прямое расстояние между двумя точками (например, между координатами посадки и высадки).	Используется для сравнения с фактическим пройденным расстоянием (например, из одометра).
Аномалии расстояния	Случаи, когда фактическое расстояние значительно превышает геодезическое –	Отфильтровываются или анализируются отдельно.

Термин	Определение	Связи
	возможный выброс или ошибка данных.	
<u>Час события</u> (pickup_hour)	Целочисленный признак (0–23), извлечённый из временной метки.	Позволяет анализировать суточные паттерны.
<u>Стоимость мили</u> (cost_per_unit)	Отношение стоимости услуги к пройденному расстоянию (например, <code>fare_amount / trip_distance</code>).	Характеризует тарификацию, может выявлять аномалии.
<u>Фильтрация по ограничивающему прямоугольнику</u> (bounding box)	Ограничение координат диапазонами широт и долгот, соответствующими исследуемой территории.	Удаляет выбросы (некорректные GPS-координаты).